

지능형 문서 관리 시스템 개발 실무 가이드

GenAI와 RAG 아키텍처를 활용한 지식 엔진 구축 전략

Junior Developer Training Series | Instructor Gemini

왜 지금 '지능형' 시스템인가?



검색의 한계 극복

단순 키워드 매칭을 넘어 질문자의 '의도'와 '맥락'을 파악하는 의미론적 검색(Semantic Search)이 필요합니다.



비정형 데이터의 자산화

기업 데이터의 80%를 차지하는 PDF, Word 등 비정형 문서를 AI가 읽고 답변할 수 있는 지식으로 전환합니다.




신속한 의사결정 지원

수천 페이지의 매뉴얼을 직접 읽지 않고도 필요한 정보를 즉시 요약 및 추출하여 업무 효율을 극대화합니다.

| 핵심 개념: LLM과 Embedding


1. LLM (Large Language Model)

텍스트를 생성하고 문맥을 파악하는 시스템의 '두뇌' 역할을 수행합니다.




RAG (Retrieval-Augmented Generation)

- ✓ **Retrieval (검색):** 사용자의 질문과 관련된 문서 조각을 Vector DB에서 찾아냅니다.
- ✓ **Augment (증강):** 검색된 정보를 질문과 함께 LLM에 전달할 프롬프트에 포함시킵니다.
- ✓ **Generation (생성):** 제공된 지식만을 근거로 LLM이 정확한 답변을 생성합니다.



| 데이터 파이프라인 전체 공정



텍스트 추출과 전처리 전략



레이아웃 보존 추출

단순 텍스트 추출이 아닌, 표(Table)와 이미지 캡션을 올바르게 인식하여 구조화하는 것이 성능의 핵심입니다.



데이터 정제 (Cleaning)

불필요한 공백, 머리말/꼬리말, 중복 데이터를 제거하여 임베딩의 노이즈를 최소화해야 합니다.

청킹(Chunking) 최적화 전략

-  **Fixed-size Chunking:** 단순 고정 길이 분할 (구현은 쉽지만 문맥 손실 위험)
-  **Recursive Character Chunking:** 문단, 문장 단위를 인식하여 계층적으로 분할 (가장 권장됨)
-  **Semantic Chunking:** 의미의 변화를 감지하여 유동적으로 분할 (높은 성능, 비용 발생)
-  **Overlap 설정:** 인접한 청크 간에 일부 텍스트를 중첩시켜 문맥의 단절을 방지

| Vector Database: 지식의 저장소

100ms

평균 검색 응답 속도

고차원 유사도 검색의 엔진

Vector DB는 수백만 개의 문서 청크 중 질문과 가장 유사한 것을 '거리 계산'을 통해 즉시 찾아냅니다.

주요 솔루션: Pinecone, ChromaDB, Milvus, Weaviate

검색 성능 비교: Hybrid Search의 필요성

Keyword (BM25)

55% Accuracy

Vector Only

78% Accuracy

Hybrid Search

92% Accuracy

* 특정 도메인 용어 및 키워드 매칭과 맥락 검색을 결합할 때 최고의 성능을 발휘합니다.

프롬프트 엔지니어링: 답변 품질의 결정자

-  **Persona 부여:** "너는 사내 기술 지원 전문가야." 라고 명확한 역할을 설정합니다.
-  **Context 제약:** "반드시 아래 제공된 [Context] 정보만을 기반으로 답변해줘." 라고 지시합니다.
-  **Hallucination 방지:** "모르는 내용은 지어내지 말고, 모른다고 답변해줘."
-  **Format 강제:** "답변 마지막에는 참고한 문서의 제목과 페이지 번호를 적어줘."

추천 개발 스택 (Tech Stack)

Category	Recommended Technology	Key Benefits
Orchestration	LangChain, LlamaIndex	AI 워크플로우 제어의 표준 프레임워크
LLM API	GPT-4o, Claude 3.5 Sonnet	최고의 추론 성능 및 한국어 지원
Vector DB	Pinecone, ChromaDB	빠른 프로토타이핑 및 확장성 제공
Backend	FastAPI (Python)	비동기 처리 및 AI 라이브러리 친화적

할루시네이션(환각) 관리 및 신뢰성



그라운드링(Grounding) 기술

AI가 답변을 생성할 때, 반드시 검색된 문서 조각(Context)에 뿌리를 두도록 설계합니다.

출처 인용 (Citation)

답변의 근거가 된 원문 링크나 페이지를 사용자에게 직접 보여줌으로써 시스템의 투명성과 신뢰성을 확보합니다.

| RAG 성능 평가 지표 (RAGAS)



- Faithfulness (답변의 정확성)
- Answer Relevance (질문과의 관련성)
- Context Precision (검색의 정밀도)

보안 및 데이터 보호

기업의 핵심 자산인 문서가 외부로 유출되지 않도록 하는 것은 최우선 과제입니다.

- ✓ Enterprise급 API 계약 (학습 미사용 옵션)
- ✓ 개인 식별 정보(PII) 마스킹 처리
- ✓ 폐쇄망 환경을 위한 로컬 LLM (Ollama, vLLM) 고려
- ✓ 문서별 접근 권한(ACL) 관리 연동

Any Questions?

문서를 이해하는 지능형 시스템, 여러분의 손으로 직접 구축해 보세요.



E-mail: help@developer.ai | GitHub: [/idms-rag-project](https://github.com/idms-rag-project)