


LLM ARCHITECTURE DEEP DIVE

ChatGPT & Gemini

구조 및 아키텍처 분석



Transformer 기반 공통 아키텍처



※ ChatGPT와 Gemini 모두 Transformer 아키텍처를 기반으로 하며, Attention 메커니즘이 핵심입니다.

ChatGPT 아키텍처 (GPT-4 기반)

핵심 스펙

모델 패밀리

GPT-3.5 / GPT-4 / GPT-4o

아키텍처

Decoder-Only Transformer

컨텍스트 윈도우

최대 128K 토큰 (GPT-4 Turbo)

학습 방법

RLHF (인간 피드백 강화학습)

멀티모달

텍스트·이미지·오디오 (GPT-4o)

학습 파이프라인 (RLHF)

1

Supervised Fine-Tuning

고품질 데이터로 초기 학습

2

Reward Model 학습

인간 평가자 선호도 반영

3

PPO 강화학습

보상 최대화 방향으로 최적화

💡 System Prompt → User Message → Assistant Response | Autoregressive 방식으로 토큰을 순차 생성 (Decoder-Only)

Gemini 아키텍처 (Google DeepMind)

모델 티어 구성

Gemini Ultra

가장 강력. 복잡한 멀티모달 추론, 과학·코딩 태스크

Gemini Pro

균형형 모델. API 및 제품 통합에 최적화

Gemini Flash

초경량·저비용. 모바일·엣지 디바이스 대응

Natively Multimodal 설계

텍스트

이미지

오디오

비디오

코드

핵심 차별화 기술

MoE (Mixture of Experts)

필요한 전문가 파라미터만 활성화, 효율적 연산

Long Context (2M 토큰)

Gemini 1.5 Pro: 업계 최장 컨텍스트 처리

Google 인프라 통합

Search, Maps, Workspace와 네이티브 연동

ChatGPT vs Gemini — 아키텍처 비교

	ChatGPT (OpenAI)	Gemini (Google)
기본 아키텍처	Decoder-Only Transformer	Decoder-Only + Sparse MoE (Mixtrue of Experts)
학습 기법	RLHF (인간 피드백 강화학습) - PPO알고리즘 기반	RLHF + RLAIIF (AI 피드백 기반 강화학습)
멀티모달	GPT-4o (통합형)	Natively Multimodal (설계부터)
컨텍스트 길이	최대 128K 토큰 (GPT-4 Turbo)	최대 1M 토큰 (Gemini 1.5)
특화 강점	자연어 대화·코딩	장문 문서·멀티모달 추론
인프라 통합	Azure 클라우드	Google Cloud / TPU

학습 파이프라인 비교

ChatGPT 학습 파이프라인

1. Pre-training

인터넷 대규모 텍스트 데이터 (WebText 등)

2. SFT

고품질 대화 데이터로 지도 학습 Fine-Tuning

3. Reward Model

인간 선호도 학습하는 보상 모델 구축

4. PPO / RLHF

보상 신호로 정책 최적화 (강화학습)

Gemini 학습 파이프라인

1. Multimodal Pre-training

텍스트·이미지·오디오·비디오 동시 학습

2. Instruction Tuning

지시 따르기 능력 강화 Fine-Tuning

3. RLHF + CAI


헌법적 AI 원칙 기반 안전성 강화

4. MoE 최적화

전문가 라우팅 효율 개선 및 배포

Attention 메커니즘 & 핵심 혁신 기술

Multi-Head Self-Attention



$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

주요 기술 혁신

Flash Attention

메모리 효율 극대화. I/O-aware 알고리즘으로 긴 시퀀스 처리 가속

RoPE (위치 인코딩)

Rotary Position Embedding. 상대적 위치 관계를 Attention에 통합

Grouped Query Attention

KV 헤드 공유로 추론 시 메모리 대폭 절감 (GPT-4, Gemini 모두 적용)

Sparse MoE (Gemini)

입력에 따라 일부 전문가 파라미터만 활성화, 대규모 모델 효율화

활용 사례 & 에코시스템

ChatGPT 에코시스템

- ▶ ChatGPT Plus / Enterprise (웹·앱 인터페이스)
- ▶ OpenAI API — GPT-4, GPT-4o, GPT-3.5
- ▶ Plugins & GPT Store (커스텀 GPT)
- ▶ Microsoft Copilot (Azure OpenAI 통합)
- ▶ GitHub Copilot (코드 자동완성)
- ▶ Function Calling / Structured Output

Gemini 에코시스템

- ▶ Gemini 앱 (Google 계정 통합)
- ▶ Google AI Studio / Vertex AI API
- ▶ Google Workspace AI (Docs·Sheets·Gmail)
- ▶ Google Search AI Overviews
- ▶ NotebookLM (장문 문서 분석)
- ▶ Gemini Code Assist (개발 도구)

요약 및 향후 전망

공통점

두 모델 모두 Transformer + Attention 메커니즘 기반. RLHF로 사람 친화적 응답 학습

ChatGPT 강점

생태계 성숙도, 플러그인 확장성, 코딩·대화 특화, Microsoft 인프라 통합

Gemini 강점

Natively Multimodal, 초장문 컨텍스트(1M), MoE 효율, Google 서비스 연동

공통 트렌드

멀티모달 통합 고도화, 에이전트 AI, 더 긴 컨텍스트, 추론 비용 절감

LLM은 빠르게 진화 중 — 아키텍처 이해가 올바른 도구 선택의 출발점입니다.